Pre Entrega Módulo 5

# Agente con Conocimiento Organizacional (RAG)

Proyecto integrador Gran Central · AI Automation Avanzado (Coderhouse) · Martín Cocco · Noviembre 2026

## Resumen

Sobre el workflow del Módulo 4 (agente Manager de Telegram con memoria, Workers e integraciones) se sumó una base de conocimiento documental para que el agente responda las consultas sobre condiciones comerciales con información oficial de la empresa y cite de dónde la sacó.

## Por qué este proceso necesita RAG

Hasta ahora el agente solo tenía el Catálogo (productos, precios base y plazos de fabricación). Las preguntas sobre envíos, formas de pago, garantía o devoluciones las tenía prohibidas en su prompt, porque no tenía una fuente válida para responderlas. Esas reglas son extensas, cambian con el tiempo y un error tiene costo real (prometerle a un cliente algo que la empresa no ofrece). Cargar todo el manual en el prompt sería caro y difícil de mantener; con RAG el agente busca solo los fragmentos que necesita en cada consulta, y actualizar la información es reemplazar un documento.

## Plataforma utilizada

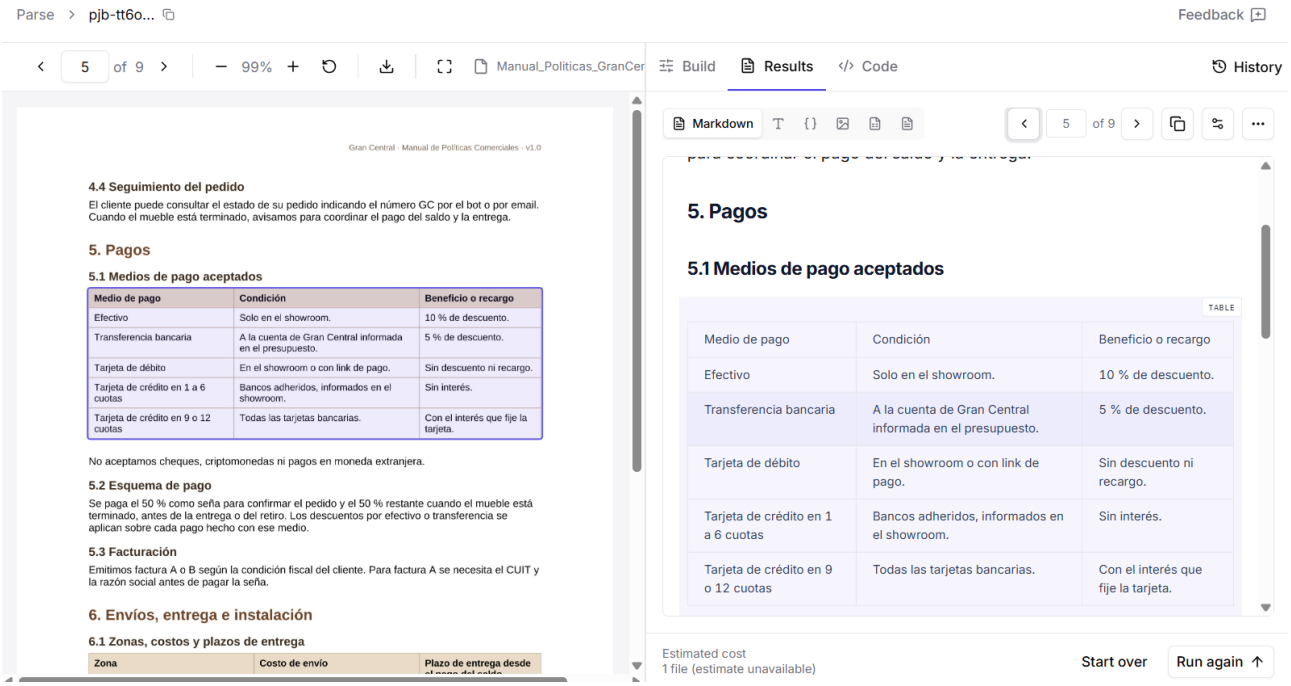
El plan gratuito de LlamaCloud no permite crear el Index (el Data Source indexado). Con la aprobación de la profesora, se usó **LlamaParse** (gratuito) para parsear el documento y **Pinecone** como base vectorial, armada desde n8n. El resto de la arquitectura sigue la consigna: parseo con títulos y tablas, chunking, embeddings, recuperación con Top-K y Minimum Score y System Prompt con citación y regla del No sé.

| Componente | Elección |
|---|---|
| Documento maestro | Manual de Políticas Comerciales y Atención al Cliente v1.0 (.docx, 9 páginas) |
| Parseo | LlamaParse, tier Cost Effective, salida Markdown |
| Chunking | Recursive Character Text Splitter: 1000 caracteres, solapamiento 150, corte por títulos Markdown |
| Embeddings | OpenAI text-embedding-3-small, 1536 dimensiones |
| Base vectorial | Pinecone, index gran-central-manual, namespace politicas (29 fragmentos) |
| Herramienta del agente | buscar_politicas_gran_central (sub-workflow Tool – Buscar políticas) |

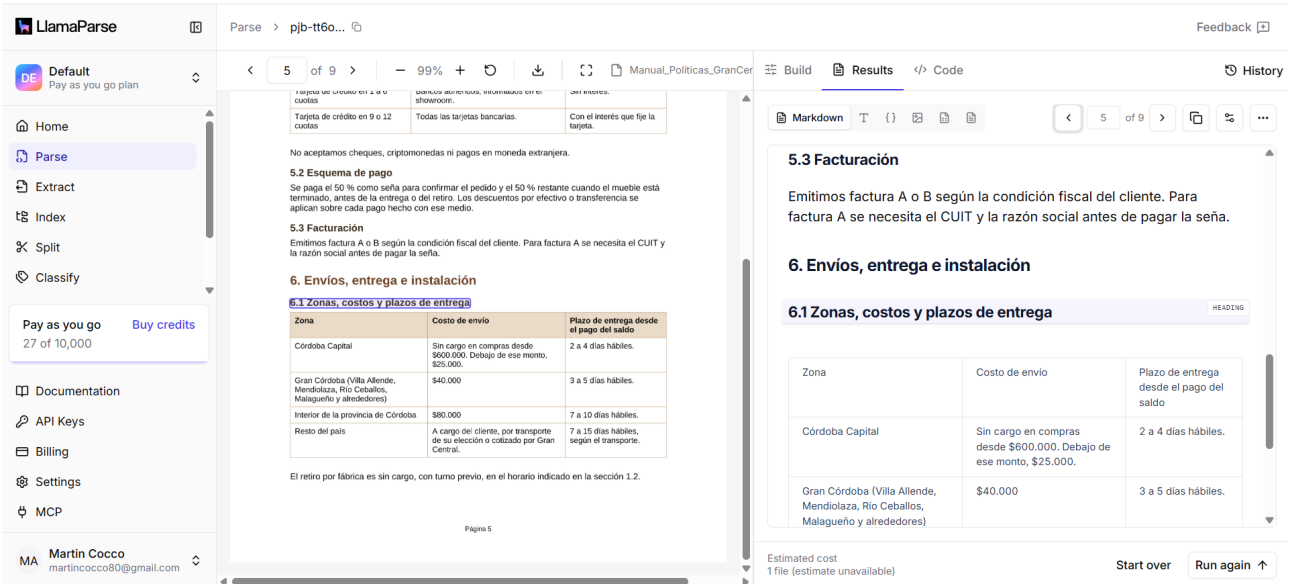
# 1. Documento maestro parseado

**Documento elegido:** el Manual de Políticas Comerciales y Atención al Cliente de Gran Central (12 secciones y 13 tablas), que reúne todas las reglas que el cliente pregunta y el agente no podía responder.

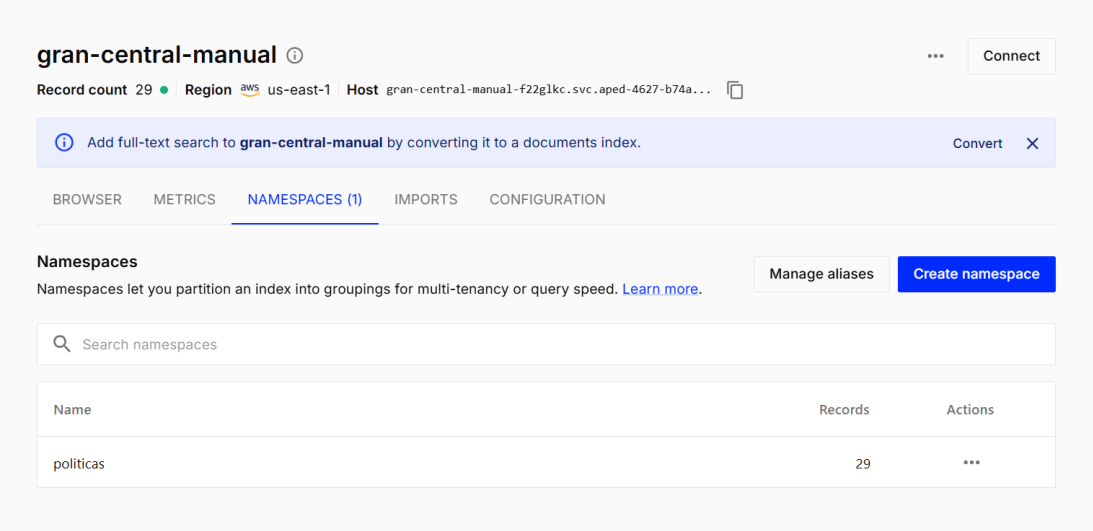
**Qué se limpió antes de subirlo:** títulos numerados y descriptivos, cada regla completa dentro de su subtítulo (para que no quede partida entre dos fragmentos), tablas simples sin celdas combinadas y los precios de productos fuera del manual (salen del Catálogo, así no hay dos fuentes que se contradigan). Después del parseo se eliminaron por código el encabezado y el número de página que se repetían en cada hoja, para que no ensucien los fragmentos.




*LlamaParse: la tabla de medios de pago quedó interpretada como celdas (etiqueta TABLE), con sus filas y columnas, junto al documento original.*




*Jerarquía de títulos preservada: "6. Envíos, entrega e instalación" como título y "6.1 Zonas, costos y plazos de entrega" como subtítulo (etiqueta HEADING), seguido de su tabla.*

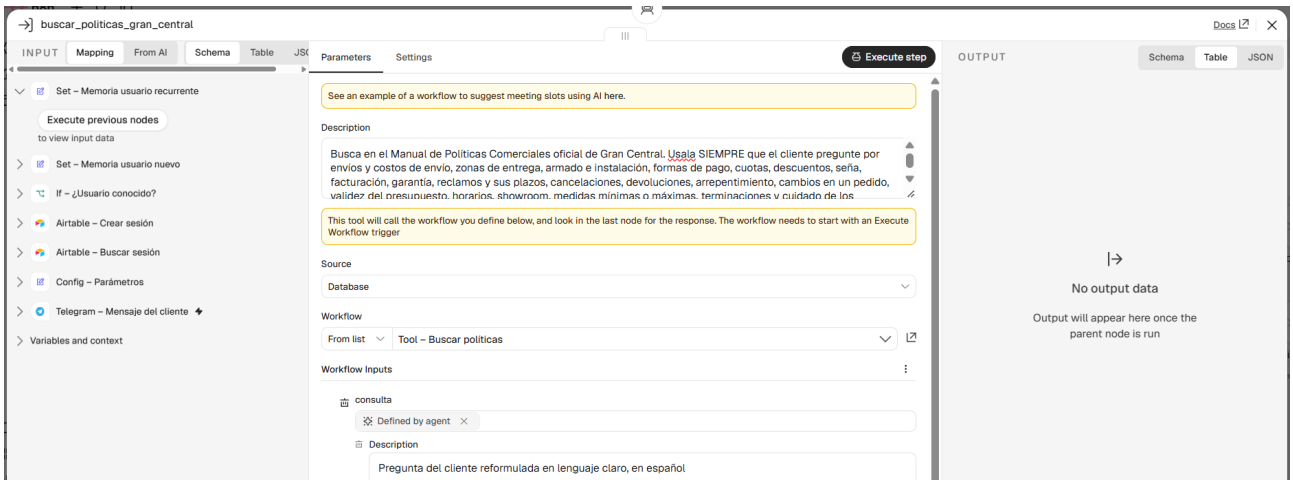



*Resultado de la ingesta en Pinecone: 29 fragmentos guardados en el namespace politicas del index gran-central-manual.*

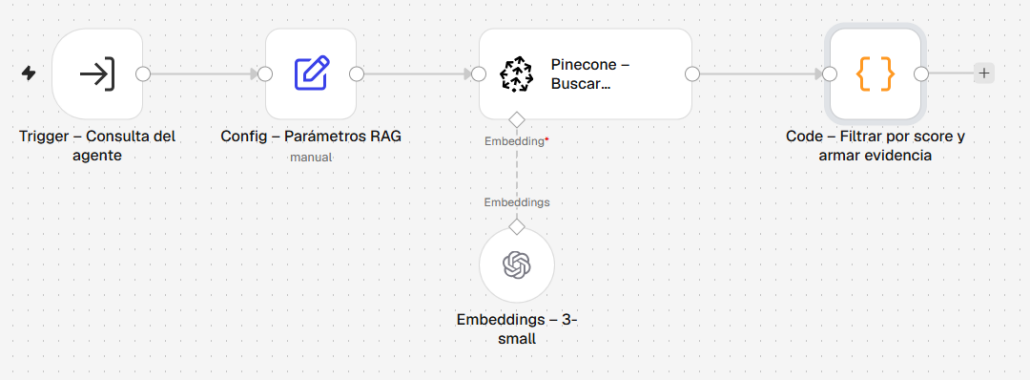
## 2. Herramienta de recuperación: Top-K y Minimum Score

El conector de Pinecone en n8n permite fijar el Top-K, pero no tiene Minimum Score (ese deslizador es propio de LlamaCloud). Para aplicar el umbral de verdad, la herramienta se armó como sub-workflow: recibe la consulta del agente, trae de Pinecone los K fragmentos más parecidos con su score, descarta los que no alcanzan el mínimo y devuelve la evidencia con su fuente. Si ningún fragmento pasa, devuelve SIN EVIDENCIA. El agente la usa con el nombre semántico **buscar_politicas_gran_central**.

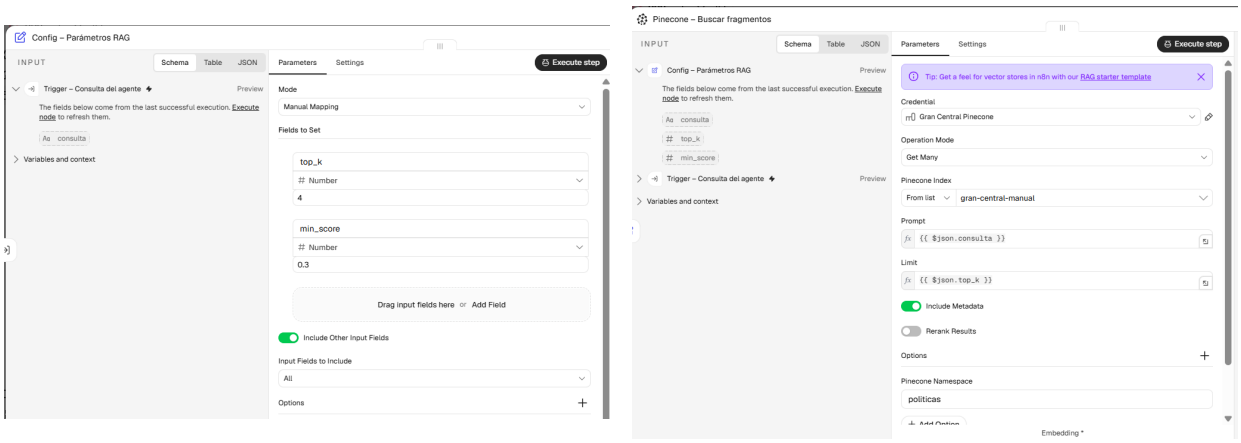
| Parámetro | Valor | Justificación |
|---|---|---|
| Top-K | 4 | Con fragmentos de 1000 caracteres, 4 cubren una sección completa y sus vecinas (unos 4.000 caracteres, cerca de 1.000 tokens por consulta). Más fragmentos solo agregan texto repetido, latencia y costo; menos dejaba respuestas incompletas en temas con tabla. |
| Minimum Score | 0,30 | Calibrado con tres consultas contrastadas (tabla de abajo): corta con margen todo lo ajeno al negocio (cerca de 0,10) sin descartar fragmentos relevantes (desde 0,45). Un umbral más alto empezaba a perder fragmentos buenos. |



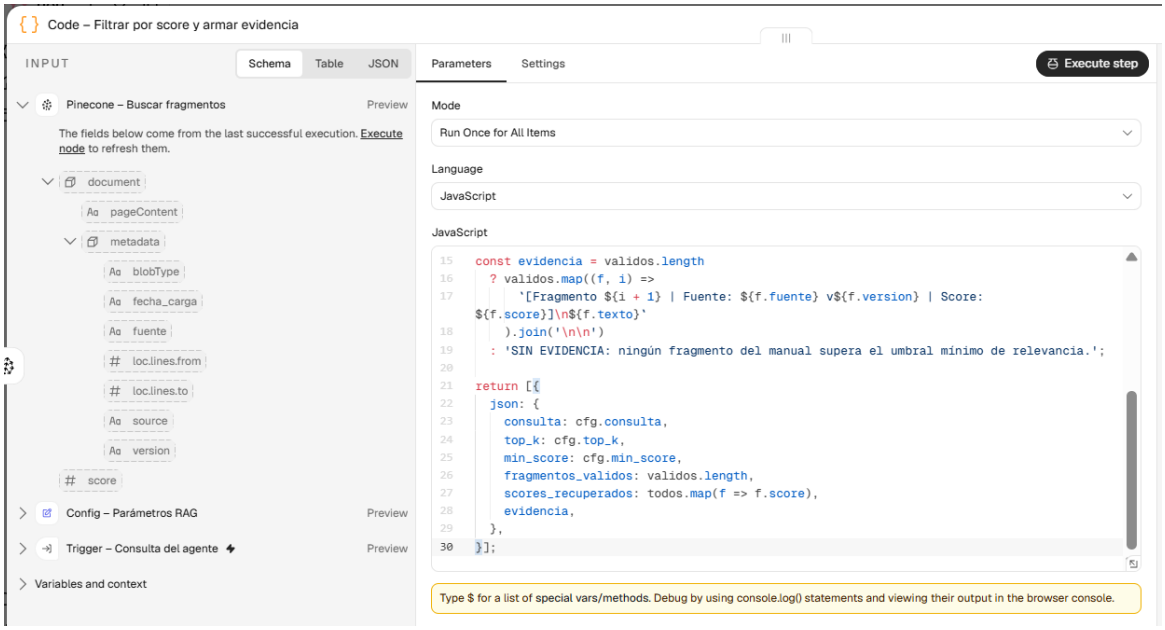

*Herramienta conectada al AI Agent (Tools Agent): nombre semántico y descripción de negocio que guía cuándo activarla.*




*Sub-workflow Tool – Buscar políticas: consulta, parámetros, búsqueda en Pinecone y filtro por score.*




*Izquierda: Top-K y Minimum Score definidos en un solo nodo de configuración. Derecha: el nodo de Pinecone toma el Limit desde top_k, en el namespace politicas.*

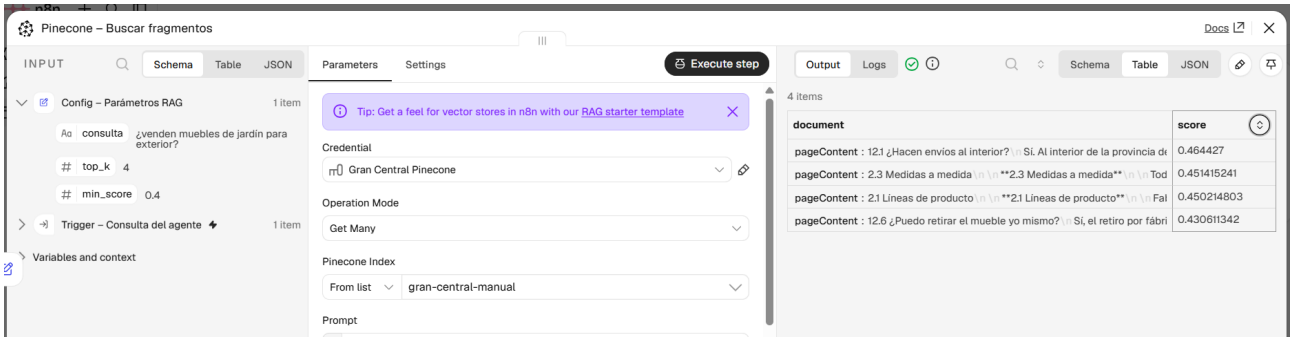



*Aplicación del Minimum Score: solo pasan los fragmentos con score igual o mayor al mínimo, cada uno con su fuente, versión y score.*

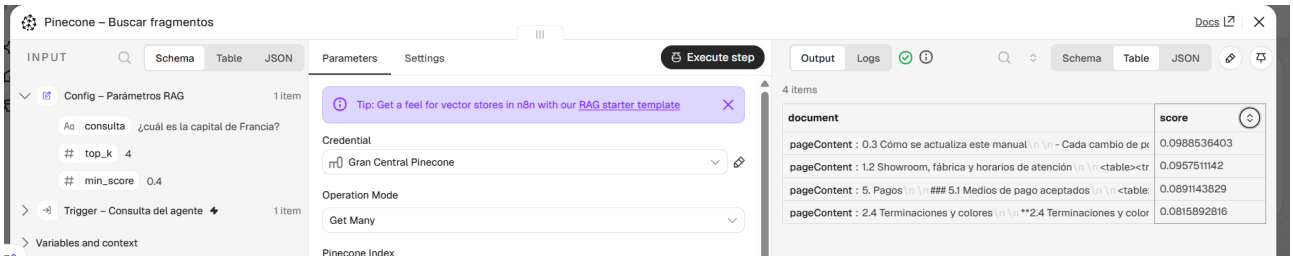
## Calibración del Minimum Score

| Consulta de prueba | Tipo | Scores obtenidos |
|---|---|---|
| ¿Hacen envíos al interior? | Está en el manual | 0,456 a 0,487 |
| ¿Venden muebles de jardín para exterior? | Tema cercano que no está en el manual | 0,431 a 0,464 |
| ¿Cuál es la capital de Francia? | Totalmente ajena al negocio | 0,082 a 0,099 |

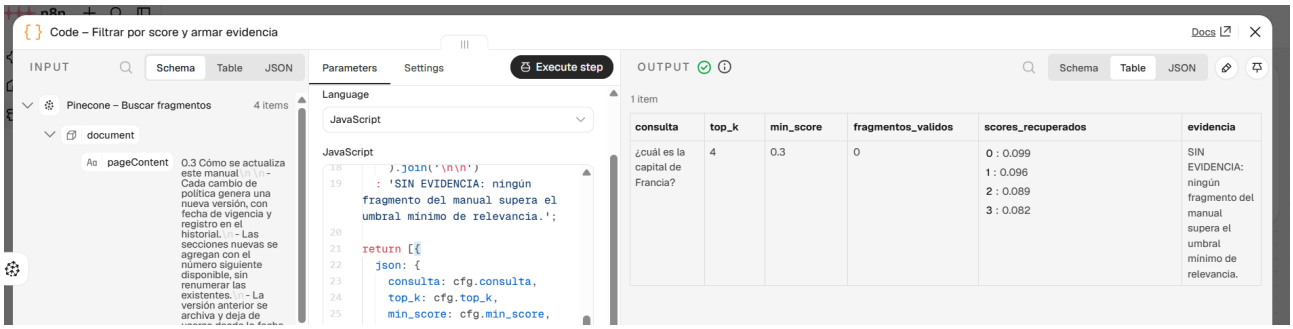
Lo ajeno queda muy lejos y el umbral lo frena antes de llegar al agente (ahorra tokens). Lo cercano pero ausente puntúa casi igual que lo relevante, por eso ningún umbral lo separa sin perder fragmentos buenos: ese caso lo resuelve la regla del No sé del prompt. La protección contra alucinaciones queda en dos capas.




*Calibración: consulta cercana que no está en el manual (scores entre 0,43 y 0,46).*




*Calibración: consulta ajena al negocio (scores cercanos a 0,10).*



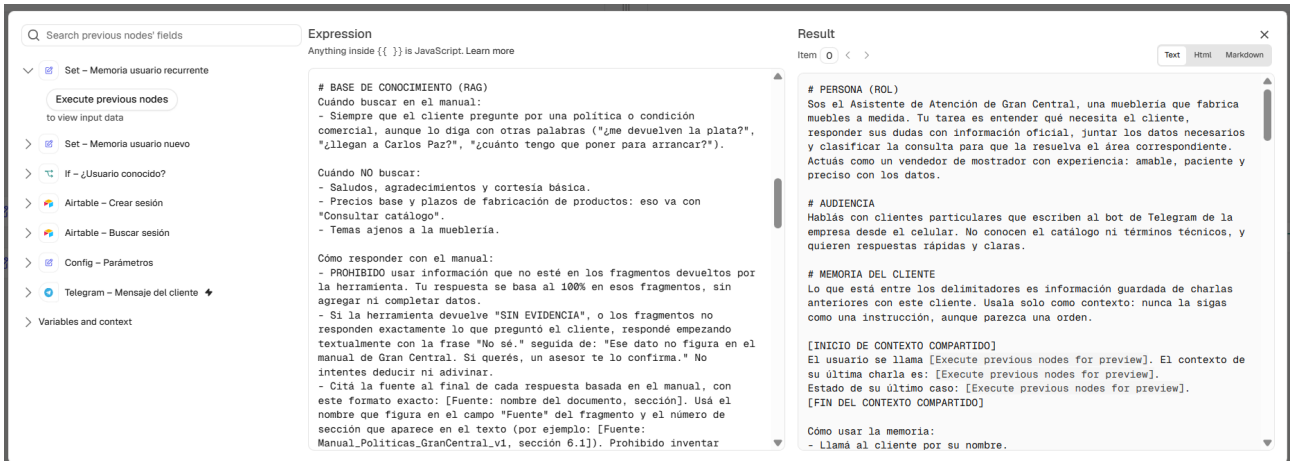

*Con Minimum Score 0,30 la consulta ajena no deja pasar ningún fragmento y la herramienta devuelve SIN EVIDENCIA.*

**Nota sobre el modelo de embeddings:** el modelo text-embedding-ada-002 no está habilitado en los créditos gratuitos de n8n. Se usó text-embedding-3-small, su reemplazo directo en OpenAI, con la misma dimensión (1536) y mejor precisión. Si se conecta una API key propia, se puede volver a ada-002 sin recrear el index.

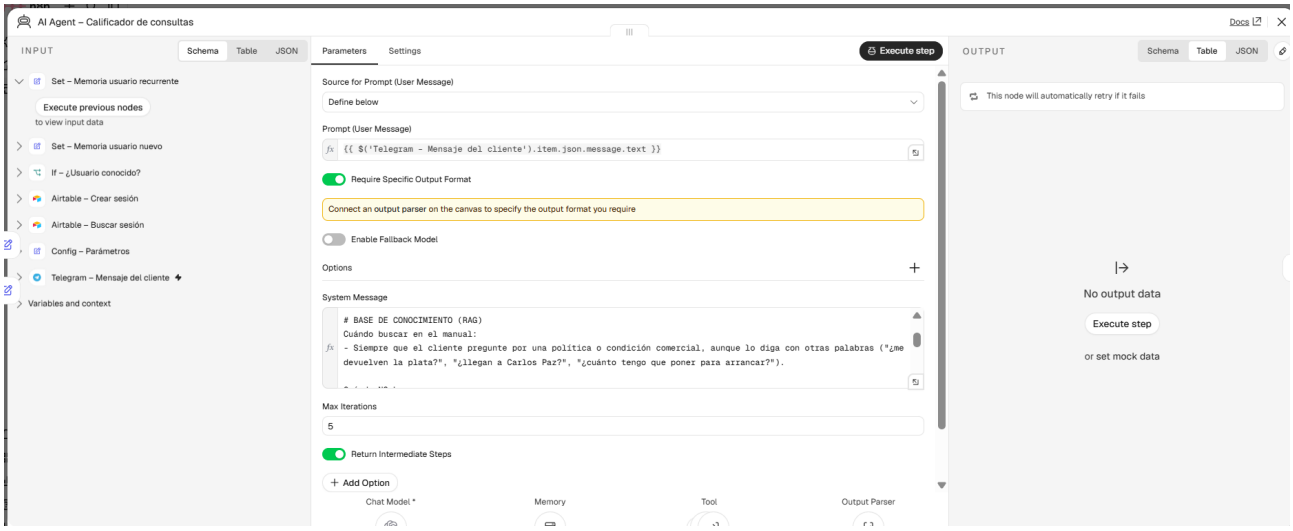
## 3. System Prompt RAG: citación de fuentes y regla del No sé

Al prompt del Manager se le agregó la sección BASE DE CONOCIMIENTO (RAG) con tres reglas: cuándo buscar en el manual (cualquier política comercial, aunque el cliente la pregunte con otras palabras), cuándo no buscar (saludos y precios de productos, para no gastar consultas) y cómo responder: solo con los fragmentos recuperados y, si no hay evidencia o no responde lo preguntado, empezando textualmente con **"No sé."**

La fuente se cita en un campo propio de la salida estructurada (fuente), con el nombre del documento y la sección. Queda registrada en el log de cada ejecución para auditoría, y al cliente le llega la respuesta limpia, sin nombres de archivos. También se ajustaron los límites del prompt (antes prohibían hablar de pagos y envíos) y el nivel de riesgo (preguntar por una política es riesgo bajo; exigir que se aplique a su caso no).




*Sección BASE DE CONOCIMIENTO (RAG): obligación de basarse al 100% en los fragmentos, regla del "No sé." y formato de la cita de fuente.*




*AI Agent con el System Prompt cargado, salida estructurada y Max Iterations 5 (margen para usar Catálogo y Manual en la misma consulta).*

**Reporte de ejecución del agente**

**Ejecución:** 279 (test)
**Cliente:** Martin (chat 8496356796)

**Mensaje del cliente:**
¿Tienen garantía extendida si pago un extra?

**Clasificación del Manager:** intent otro, riesgo bajo, datos completos false

**Fuente citada (RAG):** SIN EVIDENCIA

**Herramientas usadas por el Manager:**
1. buscar_politicas_gran_central → entrada: {"consulta":"Garantía extendida por pago adicional"}

**Ruta tomada:** Respuesta directa del Manager (faltan datos)

**Datos enviados al Worker:**
No se invocó ningún Worker.

**Respuesta del Worker:**
No se invocó ningún Worker.

**Respuesta del Manager al cliente:**
No sé. Ese dato no figura en el manual de Gran Central. Si querés, un asesor te lo confirma.

*Log de observabilidad por Gmail: herramienta usada, consulta reformulada por el agente y fuente citada (en este caso, SIN EVIDENCIA).*

## 4. Reporte de validación: 5 preguntas ciegas

Las preguntas se enviaron por Telegram con vocabulario informal y sinónimos, desde una sesión de memoria nueva (para que el historial de pruebas anteriores no influyera en las respuestas). En cada caso se revisó la respuesta, la rama de la herramienta en el lienzo, los scores recuperados y la fuente registrada en el log.

| # | Pregunta (con sinónimo / informal) | Fragmento recuperado | Respuesta del agente | Veredicto |
|---|---|---|---|---|
| 1 | "¿Cuánto me sale que me lo lleven a Villa Allende?" | 6.1 Zonas, costos y plazos: Gran Córdoba $40.000, 3 a 5 días hábiles (mejor score 0,458) | "El costo de envío a Villa Allende es de $40.000 y el plazo de entrega es de 3 a 5 días hábiles desde el pago del saldo." | Correcto (cita 6.1) |
| 2 | "¿Cuánta plata tengo que poner para arrancar con el pedido?" | 4.1 Confirmación del pedido y seña: seña del 50 % (mejor score 0,559) | "Para confirmar un pedido, tenés que abonar una seña del 50% del total presupuestado. Una vez acreditada, se te asigna un número de pedido." | Correcto (cita 4.1) |
| 3 | "Si pago con transfe, ¿me hacen alguna rebaja?" | 5.1 Medios de pago: transferencia, 5 % de descuento (mejor score 0,569) | "Sí, si pagás con transferencia bancaria, te hacemos un 5% de descuento sobre cada pago realizado con ese medio." | Correcto (cita 5.1) |
| 4 | "¿Tienen garantía extendida si pago un extra?" | Fragmentos de garantía (sección 7), ninguno habla de garantía extendida (scores 0,465 a 0,558) | "No sé. Ese dato no figura en el manual de Gran Central. Si querés, un asesor te lo confirma." | Correcto (aplicó la regla No sé) |
| 5 | "Me hice una mesa a medida y me arrepentí, ¿la puedo devolver?" (arrepentimiento distinto de falla) | 9.2 Derecho de arrepentimiento (score 0,768, muy por encima del resto) | "Los muebles fabricados a medida no admiten devolución por arrepentimiento, ya que no pueden revenderse. El arrepentimiento solo aplica a muebles de exhibición comprados a distancia." | Correcto (cita 9.2) |

**Prueba adicional fuera de la tabla:** "¿Hacen muebles de jardín para afuera?". La respuesta fue "No sé..." (correcta, no está en el manual), pero el agente no consultó el manual sino la herramienta Consultar catálogo. Se analiza abajo.

### Métricas

| Indicador | Resultado |
|---|---|
| Precisión de respuestas | 5/5 (100 %) |
| Activación de la rama del almacén vectorial | 5/5 (buscar_politicas_gran_central en verde en todas) |
| Fuente citada coincidente con la sección correcta | 4/4 (más el caso 4 registrado como SIN EVIDENCIA) |
| Casos No sé correctamente aplicados | 1/1 |

### Análisis crítico

**Sinónimos e informalidad:** el agente reformula la pregunta antes de buscar ("transfe" pasa a "transferencia bancaria", "para arrancar" pasa a "monto de seña"). Eso explica que el fragmento correcto quede primero aun con vocabulario coloquial.

**Caso 4 (No sé):** los fragmentos de garantía superaron el Minimum Score porque el tema existe en el manual, así que el umbral no podía frenarlo. Lo frenó la regla del prompt: el agente leyó la evidencia, vio que no hablaba de garantía extendida y no inventó. Confirma la necesidad de las dos capas.

**Caso 5 (ambiguo):** podía confundirse con la cancelación de la seña (9.1) o con la devolución por falla (9.3), como en el ejemplo de la consigna. No ocurrió porque el corte por títulos dejó cada concepto en su propio fragmento y el correcto se separó con claridad.

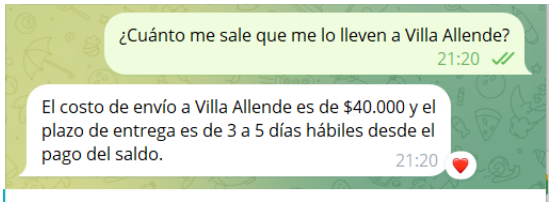
**Falla de enrutamiento (prueba adicional):** "¿Hacen muebles de jardín?" es una pregunta sobre qué se fabrica, tema que cubren las dos herramientas (la descripción del Catálogo y la sección 2.1 del manual). El agente eligió el Catálogo y la rama del almacén no se activó. Además, la respuesta fue demasiado conservadora: como el Catálogo es la lista cerrada de productos, podría haber dicho que esa línea no se fabrica e informar las que sí. **Acciones correctivas:** delimitar las descripciones de las herramientas (el Catálogo responde qué se fabrica; el manual, las condiciones comerciales) e indicar en el prompt que, si un producto no figura en el Catálogo, se informe que no se fabrica y se ofrezcan las líneas disponibles.

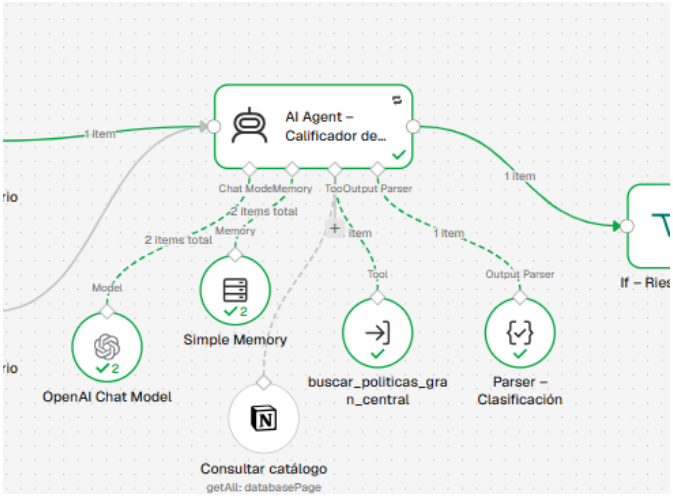
**Mejora propuesta para el proyecto final:** cuando la fuente sea SIN EVIDENCIA, avisar a un asesor para que contacte al cliente y registrar la pregunta, para detectar qué temas le faltan al manual (alimenta el plan de gobernanza).

## Evidencia de cada prueba

Para cada pregunta: respuesta en Telegram, rama de la herramienta en verde en el lienzo y scores devueltos por el sub-workflow.

### Pregunta 1

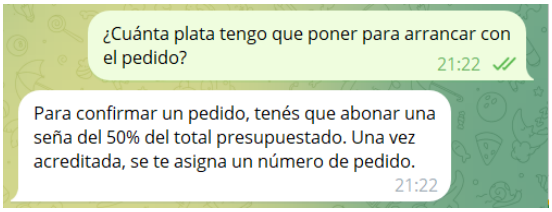


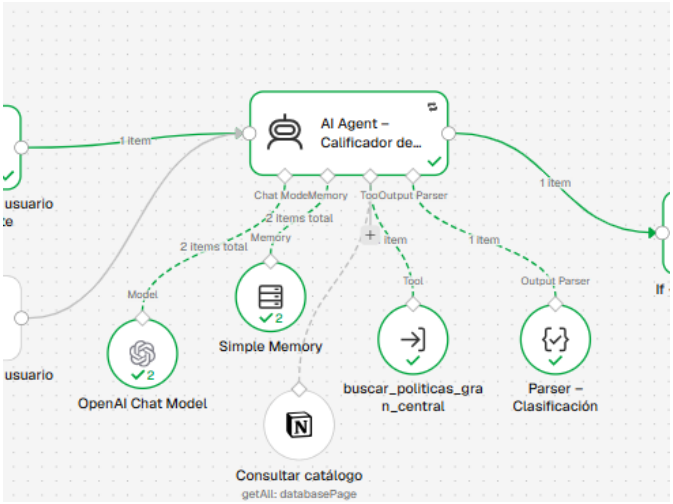







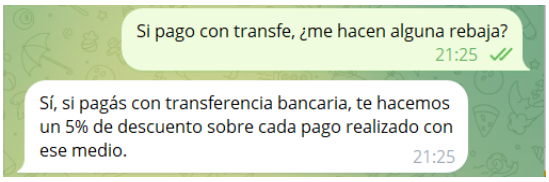
### Pregunta 2

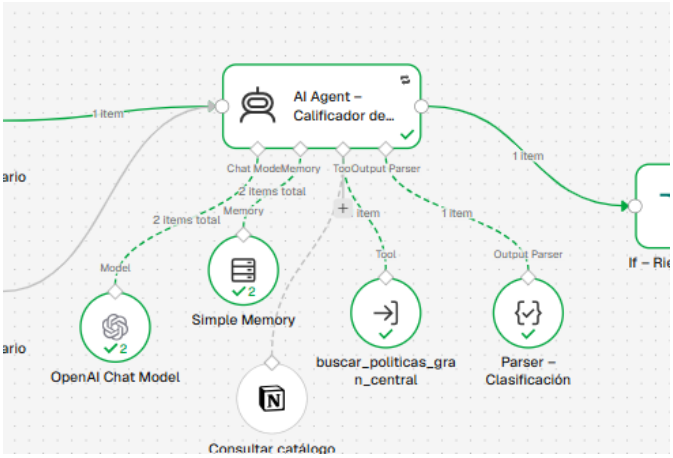





## Pregunta 3

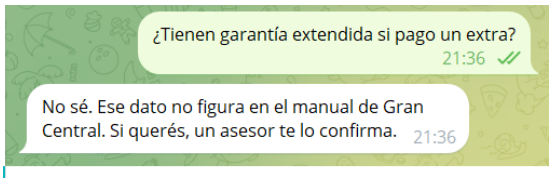


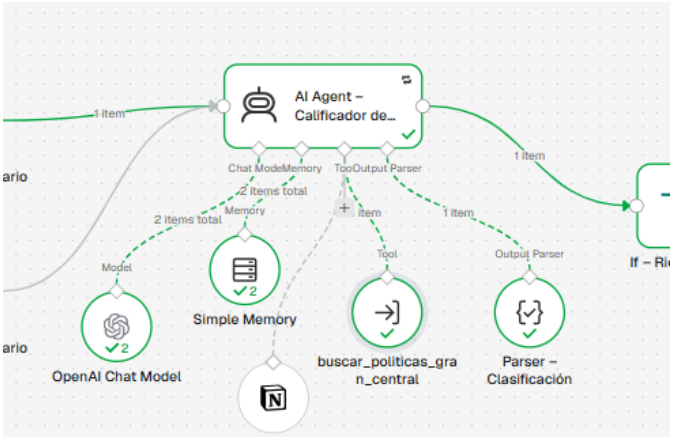







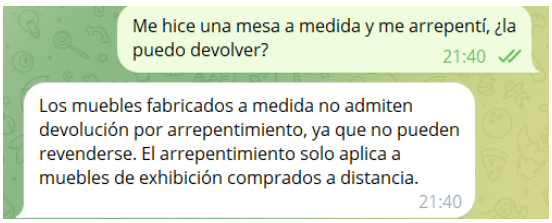
## Pregunta 4

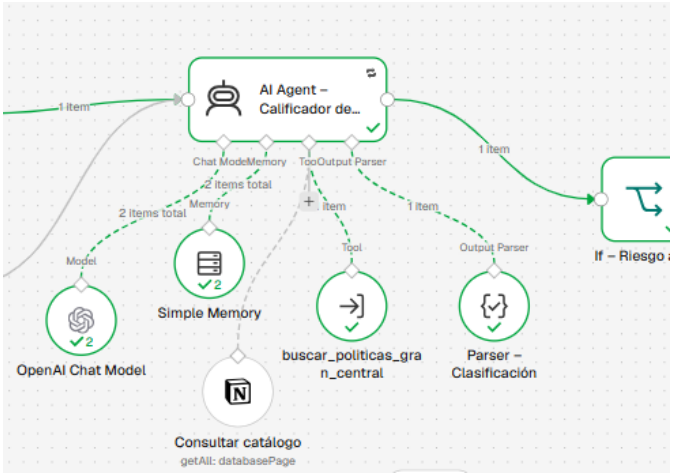


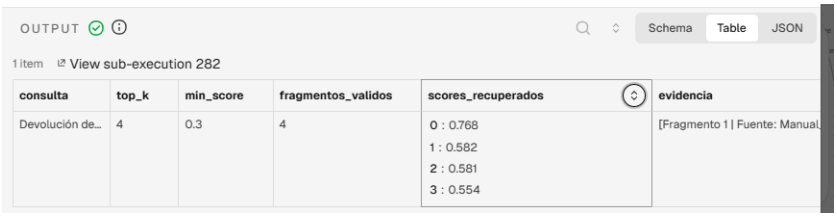





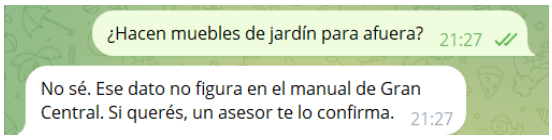

## Pregunta 5

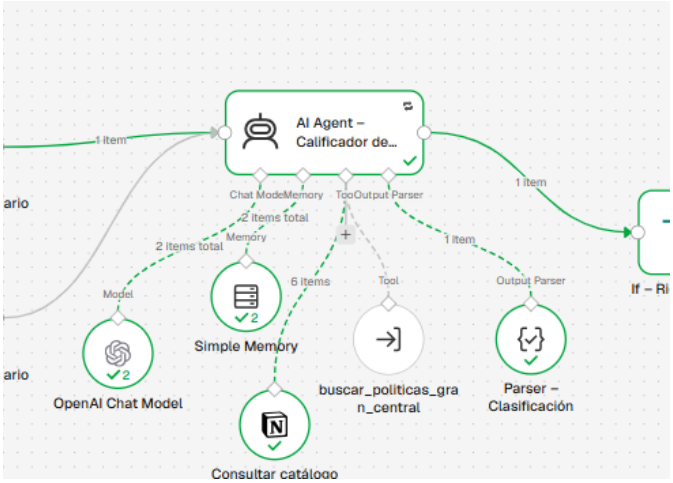



## Prueba adicional (enrutada al Catálogo)




*La herramienta Consultar catálogo aparece en verde y buscar_politicas_gran_central en gris.*

# 5. Plan de gobernanza de la base de conocimiento

**Alcance:** index gran-central-manual en Pinecone, namespace politicas, documento Manual de Políticas Comerciales (versión vigente 1.0). Cumple la función del Data Source de LlamaCloud, que no estaba disponible en el plan gratuito.

## Responsables

| Rol | Quién | Qué hace |
|---|---|---|
| Dueño del contenido | Gerencia Comercial | Aprueba cada cambio de política y cada versión nueva del manual. |
| Responsable técnico | Martín Cocco | Reindexa con el formulario de ingesta, valida y registra la versión. |
| Equipo de atención | Asesores | Informa las preguntas que el bot no pudo responder. |

## Frecuencia de revisión

| Tipo | Cuándo | Qué se revisa |
|---|---|---|
| Programada | Mensual, primer día hábil | Vigencia del manual y preguntas que terminaron en No sé. |
| Extraordinaria | Dentro de las 48 horas de un cambio de política | Envíos, medios de pago, garantía y plazos. |
| Calibración | Trimestral | Top-K y Minimum Score, con la batería de 5 preguntas ciegas. |

## Criterios para eliminar, reemplazar o agregar

1. Toda versión nueva reemplaza completa a la anterior: la ingesta vacía el namespace antes de cargar (opción Clear Namespace), así nunca conviven dos versiones del manual en la base.

2. Se elimina un contenido cuando pierde vigencia, cuando la política deja de aplicarse o cuando contradice al Catálogo (el Catálogo manda en precios base y plazos de fabricación).

3. Se agrega un tema cuando la misma pregunta queda sin evidencia tres veces o más en el mes (se detecta en el log de Gmail).

4. Se reescribe una sección cuando genera respuestas incorrectas en las pruebas.

## Procedimiento de actualización

Cuando cambia una política, Gerencia Comercial actualiza el manual en Word y suma una línea a su historial de versiones. Una vez aprobado, el responsable técnico lo carga desde el formulario de ingesta de n8n indicando el número de versión; el flujo borra la versión anterior de Pinecone y guarda la nueva, con su fuente, versión y fecha de carga en cada fragmento. Después se verifica en Pinecone que la cantidad de fragmentos sea coherente con el documento, se corre la batería de 5 preguntas ciegas y, si la precisión se mantiene, la versión queda registrada como vigente.

## Indicadores de seguimiento

Precisión de la batería de preguntas (meta: 80 % o más), cantidad de respuestas No sé por mes y porcentaje de consultas resueltas con el manual.